Universidade Federal do Estado do Rio de Janeiro (UNIRIO)
Centro de Ciências Exatas e Tecnologia (CCET)
Programa de Pós-Graduação em Informática (PPGI)

Lista de exercícios 2

Na lista de hoje, vamos verificar na prática as diferenças entre os erros (ou acertos) dentro e fora da amostra. Não se preocupe com o significado dos dados nesse momento. Utilize-os como uma matriz de números. Para os próximos exercícios, considere o dataset 1, em anexo na atividade.

1. Quantas observações tem no conjunto de dados? E quantos atributos?
2. Para estes exercícios, ignore as variáveis de índice, “ChestPain” e “Thal” que são categóricas. Faça um “drop” e crie um dataframe sem elas.
3. Verifique se há dados faltantes. Remova as observações correspondentes do dataset também.
4. Quais variáveis possuem maior correlação com a variável-alvo? Isto é, com a variável AHD.
5. Siga os passos do fluxograma apresentado na Aula 04. Primeiro, vamos dividir o dataset em dois conjuntos distintos: treino e teste. A variável-alvo nesse problema é a coluna AHD. O treino contém as observações que utilizaremos para treinar o modelo e o teste contém as observações que utilizaremos para verificar o desempenho do modelo. Utilize o parâmetro random_state=42 ao fazer essa divisão.
6. Passemos ao próximo passo. Vamos realizar o treino de quatro métodos de aprendizado estatístico. Nesse momento, não nos preocupemos com o melhor ajuste dos parâmetros para cada método. Vamos utilizar o valor padrão que já vem selecionado para cada um deles (o que significa não escrever nada no código). Começaremos do modelo mais “simples” (ou menos “flexível”) ao mais “complexo” (ou mais “flexível”, tudo entre aspas porque essas definições não são exatamente claras).
    a. Naive Bayes: https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.GaussianNB.html#sklearn.naive_bayes.GaussianNB

```
clf = GaussianNB().fit(X_train, y_train)
AcertoIn = clf.score(X_train, y_train)
AcertoOut = clf.score(X_test, y_test)
print(f"Acerto dentro da amostra: {AcertoIn}")
print(f"Acerto fora da amostra: {AcertoOut}")
# O erro é complemento do acerto
Ein = 1 - AcertoIn
Eout = 1 - AcertoOut
print(f"Erro dentro da amostra: {Ein}")
print(f"Erro fora da amostra: {Eout}")
```

    b. Regressão Logística: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html#sklearn.linear_model.LogisticRegression.score

   c. Árvore de Decisão: https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html#sklearn.tree.DecisionTreeClassifier
   d. Redes Neurais: https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html#sklearn.neural_network.MLPClassifier
      i. Importante: execute várias vezes as redes neurais. Observe que cada vez ela apresenta um resultado diferente. Isso se deve ao seu início aleatório, que não garante o melhor resultado possível para aquele modelo. Estudaremos isso mais a frente.
      ii. Somente para esse caso, vamos selecionar alguns parâmetros fíxos. Crie um modelo de Redes Neurais que contenha o parâmetro random_state=1, outro com random_state=22 e outro co max_iter=2000 e random_state=11.

7. Repita os exercícios 1, 4 e 5 para o dataset 2 (esse dataset já vem sem as colunas e os dados faltantes). Qual característica do dado mudou em relação ao dataset 1?
8. Repita os exercícios 1, 4 e 5 para o dataset 3 (esse dataset já vem sem as colunas e os dados faltantes). Qual característica do dado mudou em relação ao dataset 1?
9. Agora, analise os acertos e erros dentro da amostra para os três datasets. Para cada um dos 12 modelos treinados (4 modelos vs 3 datasets) indique se elas aparentam ter sido sobreajustados (overfit), subajustados (underfit) ou estão ajustados no melhor que funciona para aquele modelo.
10. Indique para cada um dos casos abaixo, se você espera que o desempenho de um modelo mais flexível seja melhor ou pior do que um modelo menos flexível. Justifique sua resposta.
    a. O tamanho da amostra n é extremamente grande, e o número de preditores p é pequeno.
    b. O número de preditores p é extremamente grande, e o número de observações n é pequeno.
    c. A relação entre os preditores e a resposta é altamente não-linear.

Referências de códigos:

1. Verificando linhas com valores faltantes: https://datatofish.com/rows-with-nan-pandas-dataframe/
2. Removendo linhas com valores faltantes: https://www.w3schools.com/python/pandas/ref_df_dropna.asp
3. Dividindo um dataset em treino e teste: https://www.geeksforgeeks.org/how-to-do-train-test-split-using-sklearn-in-python/

4. Treinando um modelo no scikit-learn (nesse exemplo, Regressão Logística): https://towardsdatascience.com/logistic-regression-using-python-sklearn-numpy-mnist-handwriting-recognition-matplotlib-a6b31e2b166a



Autora: Laura de Oliveira Fernandes Moraes
Título: Lista de exercícios 02 sobre análise de dados e aprendizado estatístico
Site: https://www.lauramoraes.com/recursos-educacionais