Universidade Federal do Estado do Rio de Janeiro (UNIRIO)
Centro de Ciências Exatas e Tecnologia (CCET)
Programa de Pós-Graduação em Informática (PPGI)

Lista de Exercícios 3 - Teórica (exercícios do ISLP)

1. Explique se cada cenário é um problema de classificação ou de regressão, e indique se estamos mais interessados em inferência (explicação das variáveis) ou em predição. Por fim, indique n (número de observações), p (número de atributos) e a variável-alvo (variável dependente).
    a. Coletamos um conjunto de dados sobre as 500 maiores empresas dos EUA. Para cada empresa, registramos o lucro, o número de funcionários, o setor de atuação e o salário do CEO. Estamos interessados em entender quais fatores afetam o salário do CEO.
    b. Estamos considerando lançar um novo produto e queremos saber se ele será um sucesso ou um fracasso. Coletamos dados de 20 produtos semelhantes lançados anteriormente. Para cada produto, registramos se ele foi um sucesso ou um fracasso, o preço cobrado pelo produto, o orçamento de marketing, o preço da concorrência e outras dez variáveis.
    c. Estamos interessados em prever a variação percentual da taxa de câmbio USD/Euro em relação às variações semanais nos mercados de ações mundiais. Para isso, coletamos dados semanais referentes a todo o ano de 2025. Para cada semana, registramos a variação percentual do USD/Euro, a variação percentual do mercado americano, a variação percentual do mercado britânico e a variação percentual do mercado alemão.

2. Quais são as vantagens e desvantagens de uma abordagem muito flexível (em comparação com uma abordagem menos flexível) para regressão ou classificação? Em que circunstâncias uma abordagem mais flexível pode ser preferível a uma abordagem menos flexível? Quando uma abordagem menos flexível pode ser preferível?

3. Descreva as diferenças entre uma abordagem paramétrica e uma abordagem não paramétrica de aprendizado estatístico. Quais são as vantagens de uma abordagem paramétrica para regressão ou classificação (em comparação com uma abordagem não paramétrica)? Quais são suas desvantagens?

4. A tabela abaixo apresenta um conjunto de dados de treinamento contendo seis observações, três preditores e uma variável de resposta qualitativa. Suponha que desejamos usar esse conjunto de dados para fazer uma predição de Y quando X1 = X2 = X3 = 0, utilizando o método K-vizinhos mais próximos (K-nearest neighbors).

Observação	**X1**	**X2**	**X3**	**Y**
1	0	3	0	Vermelho
2	2	0	0	Vermelho

Lista de Exercícios 3 - Teórica (exercícios do ISLP)

3	0	1	3	Vermelho
4	0	1	2	Verde
5	-1	0	1	Verde
6	1	1	1	Vermelho

a. Calcule a distância euclidiana entre cada observação e o ponto de teste, X1 = X2 = X3 = 0.
b. Qual é a nossa predição para K = 1? Por quê?
c. Qual é a nossa predição para K = 3? Por quê?

5. A tabela abaixo apresenta um conjunto de dados de treinamento contendo cinco observações, um preditor (X) e uma variável de resposta quantitativa (Y). Suponha que desejamos ajustar um modelo de regressão linear simples.

Observação	**X**	**Y**
1	2.5	7.3
2	4.1	9.8
3	1.2	4.6
4	6.7	12.1
5	3.8	8.5
6	5.4	10.9

a. Calcule as médias de x e y, representadas por $\bar{x}$ e $\bar{y}$.
b. Calcule as estimativas dos coeficientes β_0 e β_1 pelo método dos mínimos quadrados.
c. Utilizando o modelo ajustado, faça uma predição para Y quando X = 6.
d. Calcule os valores estimados $\hat{y}_i$ e os resíduos/erro quadrático para cada observação da tabela.
e. Calcule a soma dos quadrados dos resíduos (RSS) e comente o que esse valor indica sobre o ajuste do modelo.